PROPOSAL PENELITIAN DATA MINING

Perbandingan Naive Bayes, Decision Tree, dan K-Nearest Neighbor untuk Klasifikasi Tingkat Risiko Kesehatan Ibu Hamil dengan Protokol Evaluasi Bebas Kebocoran Data Duplikat

Diajukan untuk memenuhi Ujian Tengah Semester Ganjil 2026/2027
Mata Kuliah Penambangan Data

Disusun oleh:

Fahmi Fatmawati Azzahra
NIM A11.2024.15831
Kelas Penambangan Data / A11.4505

PROGRAM STUDI TEKNIK INFORMATIKA – S1
FAKULTAS ILMU KOMPUTER
UNIVERSITAS DIAN NUSWANTORO
SEMARANG

2026

1. PENDAHULUAN

1.1 Latar Belakang

Kematian ibu masih menjadi masalah kesehatan global. Pada 2023, lebih dari 700 perempuan meninggal setiap hari akibat penyebab terkait kehamilan dan persalinan yang sebenarnya dapat dicegah, dan rasio kematian ibu (AKI) global masih 197 per 100.000 kelahiran hidup, jauh dari target SDGs 2030 sebesar kurang dari 70 (WHO, 2025). Sekitar 75% kematian ibu disebabkan komplikasi seperti perdarahan hebat, infeksi, dan tekanan darah tinggi selama kehamilan (preeklamsia dan eklamsia). Di Indonesia, Survei Penduduk Antar Sensus 2025 mencatat AKI sebesar 144 per 100.000 kelahiran hidup (Badan Pusat Statistik, 2026). Karena banyak komplikasi tersebut dapat dikenali dari pemeriksaan rutin—tekanan darah, gula darah, suhu tubuh, dan denyut jantung—klasifikasi dini tingkat risiko ibu hamil penting untuk menentukan prioritas pemantauan dan rujukan.

Penambangan data menawarkan cara yang objektif untuk mengklasifikasikan tingkat risiko dari data pemeriksaan tersebut. Dataset publik *Maternal Health Risk* di UCI Machine Learning Repository (Ahmed, 2020) banyak dipakai untuk tujuan ini dengan akurasi yang dilaporkan antara 61% dan 97% (Ahmed & Kashem, 2020; Kurniawan, 2025; Uddin & Karim, 2025). Namun, audit awal penulis menemukan bahwa 562 dari 1.014 baris (55,4%) dataset ini merupakan salinan persis baris lain, dengan satu kombinasi nilai berulang hingga 27 kali—pola yang konsisten dengan pembacaan sensor IoT berulang. Jika data dibagi secara acak tanpa deduplikasi, salinan yang sama dapat berada di data latih sekaligus data uji sehingga model cukup "mengingat" jawabannya. Kondisi ini merupakan kebocoran data (*data leakage*) yang membuat kinerja tampak lebih baik daripada kemampuan generalisasi sebenarnya (Kaufman et al., 2012) dan termasuk penyebab krisis reprodusibilitas pada penelitian berbasis *machine learning* (Kapoor & Narayanan, 2023).

Urgensi penelitian ini terletak pada dua hal. Pertama, pada skrining kesehatan, kinerja yang terlalu optimistis berbahaya: model tampak andal di atas kertas tetapi dapat gagal mengenali ibu berisiko tinggi (*false negative*) ketika dipakai pada pasien baru. Studi pendahuluan penulis menunjukkan macro-F1 Decision Tree turun dari 0,847 menjadi 0,613 setelah duplikasi ditangani (Subbab 2.2). Kedua, tenaga kesehatan membutuhkan model yang dapat dijelaskan, bukan sekadar akurat. Naive Bayes (NB), Decision Tree (DT), dan K-Nearest Neighbor (KNN) mewakili tiga paradigma—probabilistik, berbasis aturan, dan berbasis kemiripan—dengan karakter akurasi, kompleksitas, dan interpretabilitas yang berbeda. Oleh karena itu, penelitian ini membandingkan ketiganya dengan protokol evaluasi bebas kebocoran dan mengimplementasikan model terbaik ke dalam aplikasi web pendukung skrining.

1.2 Rumusan Masalah

1. Seberapa besar duplikasi data menggelembungkan kinerja NB, DT, dan KNN pada dataset *Maternal Health Risk* apabila tidak ditangani?
2. Bagaimana perbandingan NB, DT, dan KNN dari sisi macro-F1, *recall* kelas Risiko Tinggi, kompleksitas, dan interpretabilitas ketika dievaluasi dengan protokol bebas kebocoran?
3. Bagaimana pengaruh tuning *hyperparameter* dan inkonsistensi label terhadap kinerja setiap algoritma?
4. Bagaimana model terbaik diimplementasikan menjadi aplikasi yang menampilkan probabilitas dan alasan prediksinya?

1.3 Tujuan Penelitian

1. Mengukur besarnya inflasi kinerja akibat duplikasi dengan membandingkan evaluasi pada data mentah dan data terdeduplikasi.
2. Membandingkan NB, DT, dan KNN secara adil dengan protokol yang sama dan menentukan model terbaik berdasarkan uji statistik.
3. Menganalisis pengaruh tuning *hyperparameter* dan label yang saling bertentangan terhadap kinerja model.
4. Membangun aplikasi web Streamlit berbasis model terbaik sebagai prototipe alat bantu skrining.

1.4 Manfaat Penelitian

- **Keilmuan:** menyediakan protokol evaluasi dan kode terbuka yang dapat direplikasi, serta bukti empiris dampak duplikasi pada dataset yang banyak dipakai sehingga penelitian berikutnya dapat melaporkan kinerja secara lebih jujur.
- **Praktis:** menghasilkan prototipe alat bantu skrining edukatif bagi bidan atau kader posyandu yang menjelaskan alasan prediksinya, sekaligus dasar untuk validasi lanjutan dengan data lokal Indonesia.

Batasan masalah: data sekunder dari Bangladesh (enam atribut, tiga kelas); algoritma dibatasi pada NB, DT, dan KNN dengan *baseline* kelas mayoritas; aplikasi berupa prototipe edukatif yang belum divalidasi klinis.

2. STUDI LITERATUR

2.1 Penelitian Terdahulu

Tabel 1 merangkum penelitian terdahulu yang memakai dataset yang sama. Sebagian besar melaporkan akurasi di atas 80%, tetapi tidak satu pun menyebutkan penanganan baris duplikat.

Tabel 1. Ringkasan penelitian terdahulu pada dataset *Maternal Health Risk*

No	Peneliti	Metode	Validasi	Duplikat	Hasil utama
1	Ahmed & Kashem (2020)	Beberapa algoritma ML; *modified decision tree* (studi asal dataset)	Tidak dirinci di abstrak	Tidak disebutkan	Akurasi tertinggi 97% (*modified* DT)
2	Mustamin, Aziz, dkk. (2023)	NB Gaussian, Multinomial, Bernoulli	5-*fold* CV	Tidak disebutkan (1.014 baris)	Akurasi 82,6% (Gaussian); 84,8% (Multinomial, Bernoulli)
3	Mustamin, Buang, dkk. (2024)	5 teknik *ensemble* dibanding DT, KNN, NB	*Cross-validation*	Tidak disebutkan (1.014 baris)	*Bagged Trees* 85,6%; NB 82,6–84,8%; KNN 74,48%; DT 61,54%
4	Kurniawan (2025)	DT ID3, C4.5, NB, KNN + *grid search*	*Split* 70:30 (dipilih dari 60:40–90:10) dan 10-*fold* CV	Tidak dilakukan (1.014 baris)	DT 85,65% (setelah optimasi); KNN 82,62%, NB 61,31% (sebelum)
5	Uddin & Karim (2025)	9 algoritma (RF, XGBoost, SVM, KNN, NB, DT, dll.) + seleksi fitur Boruta	5-*fold* CV	Tidak disebutkan (1.014 baris)	RF terbaik: akurasi 89,1%, AUC 0,970
6	Saleem Altaie & Ibrahim (2026)	XGBoost, *blending*, *stacking*	*Hold-out* 80:20; SMOTEENN hanya pada data latih	Tidak disebutkan (n = 1.015)	Akurasi 80%, AUC 0,911, *recall* risiko tinggi 0,85

Keterangan: “tidak disebutkan” berarti tidak dilaporkan pada naskah/abstrak yang dapat diakses penulis.

Hasil antarstudi juga tidak konsisten: akurasi DT 61,54% (Mustamin et al., 2024) hingga 85,65% (Kurniawan, 2025), dan NB 61,31% (Kurniawan, 2025) hingga 84,8% (Mustamin et al., 2023). Kurniawan (2025) memilih rasio pembagian data berdasarkan akurasi data uji, sehingga data uji ikut memilih model. Ketika kontrol kebocoran mulai diterapkan, akurasi turun menjadi 80% (Saleem Altaie & Ibrahim, 2026). Artinya, protokol evaluasi sangat menentukan angka yang dilaporkan.

2.2 Celah Penelitian (Research Gap)

1. **Duplikasi belum ditangani.** Studi terdahulu memakai seluruh 1.014 baris tanpa melaporkan deduplikasi, padahal 55,4% baris adalah salinan, dan belum ada yang mengukur besarnya inflasi kinerja NB, DT, dan KNN akibat hal tersebut.
2. **Protokol tidak sebanding.** Rasio *split*, cara tuning, dan validasi berbeda-beda; tuning umumnya tidak dipisahkan dari pengujian (tanpa *nested cross-validation*), sehingga perbandingan algoritma tidak adil.
3. **Metrik terbatas.** Sebagian besar studi hanya melaporkan akurasi, padahal kelas menjadi tidak seimbang setelah deduplikasi dan kesalahan pada kelas Risiko Tinggi paling berbahaya; uji signifikansi statistik juga jarang dilakukan.
4. **Aspek praktis terabaikan.** Kompleksitas dan interpretabilitas model jarang dibandingkan, dan model jarang diwujudkan menjadi aplikasi yang menjelaskan prediksinya.

Celah pertama diperkuat oleh studi pendahuluan penulis (Tabel 2) yang membandingkan algoritma dengan parameter bawaan pada data mentah (Skenario A) dan data terdeduplikasi dengan validasi berbasis grup (Skenario B). Pada Skenario A, rata-rata 83,4% baris di setiap *fold* uji memiliki salinan identik di data latih, sedangkan pada Skenario B 0,0%.

Tabel 2. Studi pendahuluan: parameter bawaan, 10×10 *cross-validation* (rata-rata)

Algoritma	Akurasi A	Akurasi B	Macro-F1 A	Macro-F1 B	Selisih F1 (A − B)
Baseline (kelas mayoritas)	0,400	0,518	0,191	0,227	−0,036
Naive Bayes Gaussian	0,599	0,647	0,557	0,518	+0,039
Naive Bayes Kategorikal	0,622	0,667	0,621	0,554	+0,067
Decision Tree (CART)	0,843	0,675	0,847	0,613	+0,234
K-Nearest Neighbor (k = 5)	0,708	0,639	0,712	0,533	+0,179

2.3 Kontribusi Penelitian

1. Audit kualitas data dan protokol evaluasi bebas kebocoran (deduplikasi, validasi berbasis grup, dan *nested cross-validation*) beserta kode terbuka yang dapat direplikasi.
2. Kuantifikasi inflasi kinerja NB, DT, dan KNN akibat duplikasi pada dataset yang banyak dipakai.
3. Perbandingan adil NB (dua varian), DT, dan KNN dengan metrik yang sesuai konteks klinis (macro-F1 dan *recall* Risiko Tinggi), uji signifikansi, serta analisis kompleksitas dan interpretabilitas.
4. Aplikasi web yang menampilkan probabilitas, peringatan input di luar rentang data latih, dan penjelasan prediksi untuk setiap algoritma.

3. RANCANGAN DATASET DAN ATRIBUT

3.1 Sumber dan Cara Memperoleh Data

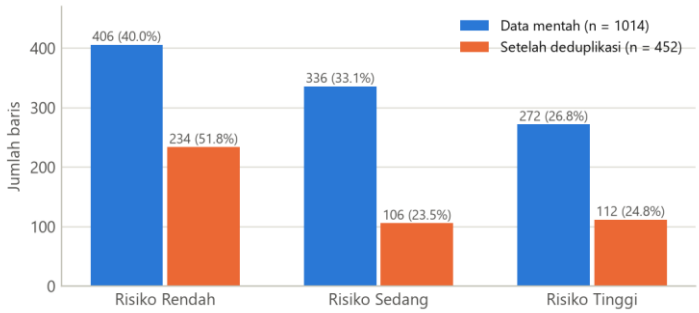
Penelitian memakai data sekunder *Maternal Health Risk* (Ahmed, 2020) yang diunduh dari UCI Machine Learning Repository (DOI 10.24432/C5DP5D, lisensi CC BY 4.0) dalam bentuk file CSV. Data asli—bukan sintetis—ini dikumpulkan dari rumah sakit, klinik komunitas, dan layanan kesehatan ibu di pedesaan Bangladesh melalui sistem pemantauan risiko berbasis IoT (Ahmed & Kashem, 2020). Data berisi 1.014 baris, enam atribut prediktor numerik, dan satu atribut target, tanpa nilai kosong. Setelah deduplikasi tersisa 452 baris unik yang menjadi data utama pemodelan. Nilai *hash* SHA-256 file dicatat agar eksperimen dapat diulang dengan data yang identik.

3.2 Atribut dan Variabel Target

Tabel 3. Atribut penelitian dan relevansinya

Atribut	Keterangan	Satuan	Rentang	Relevansi terhadap risiko
Age	Usia ibu saat hamil	tahun	10–70	Usia terlalu muda/tua meningkatkan risiko komplikasi
SystolicBP	Tekanan darah sistolik	mmHg	70–160	≥ 140 mmHg: hipertensi kehamilan (Magee et al., 2022)
DiastolicBP	Tekanan darah diastolik	mmHg	49–100	≥ 90 mmHg: hipertensi kehamilan (Magee et al., 2022)
BS	Kadar gula darah	mmol/L	6,0–19,0	Hiperglikemia/diabetes dalam kehamilan
BodyTemp	Suhu tubuh	°F	98–103	Demam sebagai tanda infeksi (WHO, 2025)
HeartRate	Denyut jantung	bpm	7–90	Takikardia pada perdarahan/infeksi; 7 bpm tidak wajar
RiskLevel	Target: tingkat risiko	kategori	3 kelas	*low*, *mid*, *high risk* (Rendah, Sedang, Tinggi)

Variabel target adalah **RiskLevel** dengan tiga kelas sehingga penelitian ini merupakan *supervised learning* klasifikasi multikelas. Setelah deduplikasi, distribusinya menjadi Risiko Rendah 234, Risiko Sedang 106, dan Risiko Tinggi 112 baris (Gambar 1).



Gambar 1. Distribusi kelas sebelum dan sesudah deduplikasi

3.3 Alasan Pemilihan Atribut

Keenam atribut dipilih karena (1) merupakan pemeriksaan rutin antenatal yang murah, cepat, dan tersedia di layanan primer seperti puskesmas dan posyandu, sehingga model dapat dipakai tanpa uji laboratorium mahal; (2) berkaitan langsung dengan penyebab utama kematian ibu, yaitu hipertensi, infeksi, dan gangguan metabolik (WHO, 2025); dan (3) secara empiris berhubungan positif dengan tingkat risiko. Korelasi Spearman terhadap target pada data unik adalah: gula darah 0,42, sistolik 0,31, suhu 0,27, usia 0,22, diastolik 0,22, dan denyut jantung 0,17. Tekanan sistolik dan diastolik saling berkorelasi (0,77), tetapi keduanya dipertahankan karena kriteria klinis memakai keduanya. Seleksi fitur tidak dilakukan karena jumlah atribut hanya enam dan semuanya relevan.

3.4 Strategi Penanganan Kualitas Data

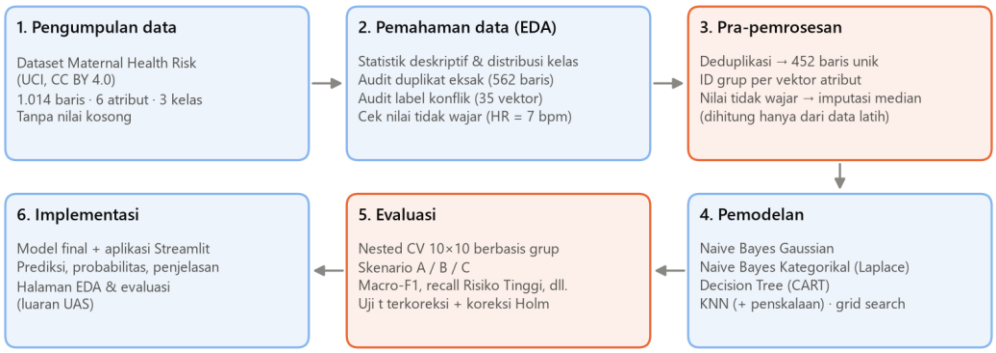
Tabel 4. Temuan audit kualitas data dan strategi penanganannya

Masalah	Temuan	Strategi penanganan
Data kosong	Tidak ada nilai kosong	Imputasi median tetap disiapkan di *pipeline* untuk data baru; median dihitung dari data latih saja.
Data duplikat	562 baris duplikat eksak (55,4%); 866 baris terlibat; berulang hingga 27×	Hapus duplikat eksak → 452 baris; pembagian data berbasis grup vektor atribut agar nilai identik tidak berada di data latih dan uji sekaligus. Data mentah hanya untuk pembanding (Skenario A).
Label tidak konsisten	35 vektor atribut identik berlabel berbeda (71 baris)	Label tidak diubah agar *ground truth* tidak dimanipulasi; baris dikunci dalam satu grup. Dampaknya diuji pada Skenario C (baris dihapus).
Nilai tidak wajar	HeartRate 7 bpm (2 baris mentah); usia 10–14 tahun (30) dan > 50 tahun (45)	Nilai di luar rentang fisiologis (mis. denyut 40–200 bpm) dijadikan kosong lalu diimputasi median data latih. Usia ekstrem dipertahankan (tercatat di sumber), dicatat sebagai keterbatasan.
Konsistensi logis	Semua baris: sistolik > diastolik	Aturan yang sama dipakai untuk validasi input aplikasi.
Atribut kategorikal	Prediktor numerik; target kategorikal	Target dikodekan otomatis; untuk NB Kategorikal atribut didiskretisasi (jumlah *bin* dan strategi dituning).
Skala & kelas tidak seimbang	Rentang atribut berbeda; Risiko Rendah 51,8%	Penskalaan untuk KNN (dipilih lewat tuning); stratifikasi; opsi *class weight* pada DT; metrik *macro*.

4. METODE PENELITIAN

4.1 Tahapan Penelitian

Penelitian mengikuti kerangka CRISP-DM (Wirth & Hipp, 2000) yang disesuaikan menjadi enam tahap (Gambar 2): pengumpulan data, pemahaman data melalui EDA dan audit kualitas, pra-pemrosesan, pemodelan, evaluasi, dan implementasi. Tahap yang berwarna oranye adalah bagian yang membedakan penelitian ini dari studi terdahulu.



Gambar 2. Alur penelitian

4.2 Konsep Algoritma dan Alasan Kesesuaian

Naive Bayes mengklasifikasikan data berdasarkan teorema Bayes dengan asumsi bahwa atribut saling independen jika kelasnya diketahui (Han et al., 2012):

$$P(C_k \mid X) \propto P(C_k)\prod_{i=1}^{n} P(x_i \mid C_k) \quad (1)$$

Varian Gaussian memodelkan atribut numerik dengan distribusi normal, sedangkan varian Kategorikal mendiskretisasi atribut lalu memakai *Laplace smoothing* (α = 1) agar tidak ada peluang nol—sesuai materi perkuliahan:

$$P(x_i \mid C_k) = \frac{1}{\sqrt{2\pi\sigma_{ik}^2}}\, exp\left(-\frac{(x_i-\mu_{ik})^2}{2\sigma_{ik}^2}\right), \quad P(x_i = v \mid C_k) = \frac{n_{ikv}+\alpha}{n_k+\alpha V_i} \quad (2)$$

NB cocok karena cepat, membutuhkan sedikit parameter—penting untuk data kecil (452 baris)—dan menghasilkan probabilitas per kelas yang dapat diuraikan per atribut.

Decision Tree (CART) membagi data secara rekursif dengan memilih atribut dan ambang yang paling menurunkan ketidakmurnian simpul, diukur dengan indeks Gini atau entropi (Han et al., 2012):

$$Gini(D) = 1 - \sum_{k=1}^{K} p_k^2, \;\; Entropy(D) = -\sum_{k=1}^{K} p_k \, log_2 \, p_k \tag{3}$$

DT dipilih karena menghasilkan aturan JIKA–MAKA yang dapat dibaca tenaga kesehatan, mampu menangkap ambang klinis (misalnya gula darah tinggi), dan tidak memerlukan penskalaan. Risiko *overfitting* dikendalikan melalui kedalaman maksimum dan jumlah minimum sampel per daun.

K-Nearest Neighbor menentukan kelas berdasarkan suara mayoritas k tetangga terdekat dengan jarak Minkowski (p = 1 Manhattan, p = 2 Euclidean):

$$d(x, z) = (\sum_{i=1}^{n} |x_i - z_i|^p)^{1/p} \tag{4}$$

KNN mewakili pendekatan berbasis kemiripan yang menangkap pola lokal tanpa asumsi distribusi. KNN juga paling rentan terhadap duplikat—salinan identik di data latih menjadi tetangga berjarak nol—sehingga relevan untuk menguji dampak kebocoran.

4.3 Persiapan Data untuk Pemodelan

Seluruh pra-pemrosesan disusun dalam satu *pipeline* (validasi rentang dan imputasi → penskalaan untuk KNN atau diskretisasi untuk NB Kategorikal → model) yang selalu di-*fit* hanya pada data latih. Karena data unik hanya 452 baris, satu kali pembagian 70:30 atau 80:20 tidak stabil, sehingga dipakai *repeated stratified group k-fold* 10×10 (100 pasangan latih–uji; Bouckaert & Frank, 2004). Tuning memakai *grid search* 5-*fold* di dalam data latih setiap *fold* luar (*nested cross-validation*) dengan skor macro-F1, sehingga data uji tidak pernah ikut memilih parameter (Varma & Simon, 2006). Implementasi memakai Python dan scikit-learn (Pedregosa et al., 2011) dengan *random seed* 42 (Tabel 5).

Tabel 5. Ruang *hyperparameter* untuk *grid search*

Algoritma	Hyperparameter dan nilai yang diuji	Kombinasi
NB Gaussian	*var_smoothing*: 10^{-12} sampai 10^{-2} (11 nilai, skala log)	11
NB Kategorikal	jumlah *bin* {3, 4, 5, 6, 8, 10}; strategi {*quantile*, *uniform*, *k-means*}; α {0,5; 1}	36
Decision Tree	kriteria {Gini, entropi}; kedalaman maks {3, 4, 5, 6, 8, tanpa batas}; min. sampel daun {1, 3, 5, 10}; bobot kelas {tidak ada, seimbang}	96
KNN	k {1, 3, …, 29}; bobot {seragam, jarak}; p {1, 2}; penskalaan {tanpa, standar, min-max}	180

4.4 Alasan Pemilihan Metode dibanding Alternatif

Metode *ensemble* seperti Random Forest atau XGBoost dapat memberi akurasi lebih tinggi (Uddin & Karim, 2025), tetapi lebih sulit dijelaskan, tuningnya lebih berat, dan lebih rentan *overfitting* pada 452 baris; karena fokus penelitian ini adalah evaluasi yang jujur dan interpretabel, *ensemble* ditempatkan sebagai pengembangan lanjutan. SMOTE tidak dipakai karena data sintetis hasil interpolasi dapat memperkuat derau dari label yang bertentangan. Validasi *hold-out* tunggal dihindari karena variansnya besar pada data kecil.

5. RANCANGAN EKSPERIMEN DAN EVALUASI

5.1 Skenario Eksperimen

Eksperimen terdiri atas tiga skenario data (Tabel 6). Pada setiap skenario, empat model (NB Gaussian, NB Kategorikal, DT, KNN) diuji dengan parameter bawaan dan hasil tuning, ditambah *baseline*, sehingga terdapat 3 × 100 *fold* × 9 = 2.700 evaluasi. Diagnosis kebocoran: persentase baris uji yang memiliki salinan identik di data latih.

Tabel 6. Skenario eksperimen

Kode	Data	Validasi	Tujuan
A	Data mentah (1.014 baris)	Stratified 10×10 CV, tiap baris diperlakukan terpisah	Mereplikasi praktik umum; pembanding untuk mengukur kebocoran
B (utama)	Data unik (452 baris)	Stratified group 10×10 CV + *nested* tuning	Estimasi kinerja yang jujur (protokol usulan)
C	Data unik tanpa label konflik (381 baris)	Sama dengan B	Analisis sensitivitas terhadap inkonsistensi label

5.2 Metrik Evaluasi

Metrik utama adalah **macro-F1**, yaitu rata-rata F1 setiap kelas dengan bobot sama sehingga kelas minoritas tidak tertutupi kelas mayoritas (Risiko Rendah 51,8%). Metrik keselamatan adalah **recall kelas Risiko Tinggi**, karena ibu berisiko tinggi yang terlewat (*false negative*) merupakan kesalahan paling berbahaya:

$$F1_{macro} = \frac{1}{K}\sum_{k=1}^{K} 2 \cdot \frac{P_k R_k}{P_k + R_k}, \quad Recall_{tinggi} = \frac{TP}{TP+FN} \tag{5}$$

Metrik pendukung: akurasi (agar sebanding dengan studi terdahulu), *balanced accuracy*, presisi Risiko Tinggi, ROC-AUC *one-vs-rest*, dan *confusion matrix*. Kompleksitas diukur dari waktu latih, waktu prediksi per 1.000 data, dan ukuran model (simpul DT, data yang disimpan KNN, parameter NB). Interpretabilitas dinilai dari bentuk penjelasannya: aturan pohon (DT), kontribusi atribut (NB), atau tetangga terdekat (KNN).

5.3 Pembandingan dan Uji Statistik

Setiap algoritma dibandingkan dengan *baseline* kelas mayoritas, antara parameter bawaan dan hasil tuning, serta antaralgoritma. Karena skor dari *k-fold* berulang saling bergantung, uji t biasa terlalu liberal; oleh karena itu dipakai *corrected resampled t-test* (Nadeau & Bengio, 2003) dengan n = 100 dan rasio data uji/latih n_2/n_1:

$$t = \frac{m_d}{\sqrt{\left(\frac{1}{n} + \frac{n_2}{n_1}\right) s_d^2}} \tag{6}$$

dengan m_d dan s_d^2 rata-rata dan variansi selisih skor dua model. Nilai p dikoreksi dengan metode Holm (Holm, 1979) karena ada banyak perbandingan sekaligus ($\alpha = 0{,}05$). Inflasi kinerja = metrik Skenario A − Skenario B. **Aturan pemilihan model terbaik** ditetapkan sejak awal: macro-F1 tertinggi pada Skenario B; jika selisihnya dengan model lain tidak signifikan, dipilih model dengan *recall* Risiko Tinggi tertinggi, lalu yang lebih mudah dijelaskan.

5.4 Keterkaitan Hasil dengan Rumusan Masalah

RM1 dijawab dengan selisih akurasi, macro-F1, dan *recall* Risiko Tinggi antara Skenario A dan B serta persentase baris uji yang memiliki salinan di data latih. **RM2** dijawab dengan macro-F1, *recall* Risiko Tinggi, uji t terkoreksi, waktu, ukuran model, dan bentuk penjelasan keempat model pada Skenario B. **RM3** dijawab dengan perubahan metrik dari

parameter bawaan ke hasil tuning, serta dari Skenario B ke C. **RM4** dijawab dengan hasil pengujian fungsional (*black-box*) aplikasi dan waktu respons prediksinya.

5.5 Luaran dan Kriteria Keberhasilan

Luaran yang diharapkan adalah perbandingan kinerja yang jujur, rekomendasi algoritma, dan aplikasi web. Target ditetapkan dari studi pendahuluan (Tabel 2), bukan dari angka studi terdahulu yang berpotensi bias. Penelitian dinyatakan berhasil apabila:

1. inflasi akibat duplikasi terukur, yaitu selisih macro-F1 Skenario A − B ≥ 0,05 pada sedikitnya satu algoritma;
2. model terbaik pada Skenario B mencapai macro-F1 ≥ 0,60 dan *recall* Risiko Tinggi ≥ 0,70, serta signifikan lebih baik daripada *baseline* (p Holm < 0,05);
3. aplikasi lolos seluruh kasus uji fungsional (input valid dan tidak valid, konversi satuan, prediksi berkas CSV) dengan waktu respons prediksi kurang dari 1 detik.

6. RENCANA PELAKSANAAN PENELITIAN

6.1 Target Capaian

Target capaian: (1) laporan penelitian lengkap untuk UAS; (2) repositori GitHub berisi data, skrip, dan model yang hasilnya dapat direproduksi; (3) aplikasi web Streamlit yang dapat diakses daring; dan (4) bahan presentasi.

6.2 Jadwal Kegiatan

Tabel 7. Jadwal kegiatan penelitian (minggu ke-1 sampai ke-8 setelah UTS)

Kegiatan	1	2	3	4	5	6	7	8
Studi literatur dan finalisasi proposal	■							
Pengumpulan data, EDA, dan audit kualitas	■	■						
Pra-pemrosesan dan penyusunan *pipeline*		■	■					
Pemodelan dan tuning NB, DT, KNN			■	■				
Eksperimen Skenario A/B/C dan uji statistik				■	■			
Pengembangan aplikasi Streamlit					■	■		
Pengujian aplikasi dan *deployment*							■	
Penyusunan laporan akhir dan presentasi UAS							■	■

6.3 Pembagian Tugas

Penelitian dikerjakan secara mandiri; seluruh tahapan—studi literatur, pengolahan data, eksperimen, pengembangan aplikasi, dan penulisan laporan—menjadi tanggung jawab penyusun dengan arahan dosen pengampu.

6.4 Rencana Implementasi dan Pemanfaatan

Model terbaik diimplementasikan sebagai aplikasi web Streamlit yang di-*deploy* dari GitHub ke Streamlit Community Cloud, dengan empat halaman: (1) **Prediksi Risiko**—input enam hasil pemeriksaan dengan konversi satuan (mg/dL, °C), kelas risiko dan probabilitasnya, peringatan bila input di luar rentang data latih, penjelasan prediksi (jalur aturan DT, kontribusi atribut NB, atau tetangga terdekat KNN), serta prediksi berkas CSV; (2) **Eksplorasi Data**; (3) **Evaluasi Model** untuk Skenario A/B/C; dan (4) **Tentang**. Aplikasi dimanfaatkan sebagai sarana edukasi dan alat bantu skrining awal bagi bidan atau kader posyandu—bukan diagnosis. Sebelum dipakai di lapangan, model perlu divalidasi dengan data ibu hamil Indonesia, misalnya data pemeriksaan antenatal di puskesmas.

DAFTAR PUSTAKA

Ahmed, M. (2020). *Maternal health risk* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5DP5D

Ahmed, M., & Kashem, M. A. (2020). IoT based risk level prediction model for maternal health care in the context of Bangladesh. *2020 2nd International Conference on Sustainable Technologies for Industry 4.0 (STI)*, 1–6. https://doi.org/10.1109/STI50764.2020.9350320

Badan Pusat Statistik. (2026). *Penduduk dan indikator kependudukan hasil Survei Penduduk Antar Sensus 2025*. Badan Pusat Statistik.

Bouckaert, R. R., & Frank, E. (2004). Evaluating the replicability of significance tests for comparing learning algorithms. Dalam *Advances in Knowledge Discovery and Data Mining (PAKDD 2004)* (hlm. 3–12). Springer. https://doi.org/10.1007/978-3-540-24775-3_3

Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (Edisi ke-3). Morgan Kaufmann.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics, 6*(2), 65–70.

Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns, 4*(9), 100804. https://doi.org/10.1016/j.patter.2023.100804

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data, 6*(4), 1–21. https://doi.org/10.1145/2382577.2382579

Kurniawan, A. (2025). Perbandingan optimasi algoritma klasifikasi decision tree, naive bayes dan KNN menggunakan optimize parameter grid pada tingkat resiko ibu hamil. *Faktor Exacta, 18*(2), 111–119. https://doi.org/10.30998/faktorexacta.v18i2.28051

Magee, L. A., Brown, M. A., Hall, D. R., Gupte, S., Hennessy, A., Karumanchi, S. A., Kenny, L. C., McCarthy, F., Myers, J., Poon, L. C., Rana, S., Saito, S., Staff, A. C., Tsigas, E., & von Dadelszen, P. (2022). The 2021 International Society for the Study of Hypertension in Pregnancy classification, diagnosis & management recommendations for international practice. *Pregnancy Hypertension, 27*, 148–169. https://doi.org/10.1016/j.preghy.2021.09.008

Mustamin, N. F., Aziz, F., Firmansyah, F., & Ishak, P. (2023). Classification of maternal health risk using three models naive bayes method. *IJCCS (Indonesian Journal of Computing and Cybernetics Systems), 17*(4), 395–404. https://doi.org/10.22146/ijccs.84242

Mustamin, N. F., Buang, A., Aziz, F., & Nur, N. H. (2024). Ensemble techniques based risk classification for maternal health during pregnancy. *ILKOM Jurnal Ilmiah, 16*(2), 190–197. https://doi.org/10.33096/ilkom.v16i2.2005.190-197

Nadeau, C., & Bengio, Y. (2003). Inference for the generalization error. *Machine Learning, 52*(3), 239–281. https://doi.org/10.1023/A:1024068626366

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Saleem Altaie, H. K., & Ibrahim, A. A. (2026). Development of an advanced maternal health risk detection system using enhanced XGBOOST and blending models. *Digital Health, 12*, 20552076261450786. https://doi.org/10.1177/20552076261450786

Uddin, M. M., & Karim, M. R. (2025). Comparative evaluation of machine learning models for maternal health risk prediction using IoT-based data. *International Journal of Statistical Sciences, 25*(2), 59–80. https://doi.org/10.3329/ijss.v25i2.85735

Varma, S., & Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics, 7*, 91. https://doi.org/10.1186/1471-2105-7-91

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 29–39.

World Health Organization. (2025, 7 April). *Maternal mortality* [Lembar fakta]. https://www.who.int/news-room/fact-sheets/detail/maternal-mortality