PROPOSAL PENELITIAN

PERBANDINGAN ALGORITMA NAIVE BAYES, DECISION TREE, DAN K-NEAREST NEIGHBOR UNTUK KLASIFIKASI TINGKAT RISIKO KESEHATAN IBU HAMIL DENGAN PENANGANAN DATA DUPLIKAT

Disusun oleh:

Fahmi Fatmawati Azzahra

A11.2024.15831

Kelas Penambangan Data / A11.4505

Dosen Pengampu:

Junta Zeniarja, M.Kom

PROGRAM STUDI TEKNIK INFORMATIKA – S1

FAKULTAS ILMU KOMPUTER

UNIVERSITAS DIAN NUSWANTORO

SEMARANG

2026

BAB I PENDAHULUAN

1.1 Latar Belakang

Angka kematian ibu (AKI) masih menjadi masalah kesehatan yang serius. Menurut WHO (2025), pada tahun 2023 lebih dari 700 perempuan meninggal setiap hari karena penyebab yang berkaitan dengan kehamilan dan persalinan yang sebenarnya dapat dicegah. AKI global masih 197 per 100.000 kelahiran hidup, jauh dari target SDGs 2030 yaitu di bawah 70, sedangkan di Indonesia hasil Survei Penduduk Antar Sensus 2025 menunjukkan AKI sebesar 144 per 100.000 kelahiran hidup (Badan Pusat Statistik, 2026). Sekitar 75% kematian ibu disebabkan oleh komplikasi seperti perdarahan hebat, infeksi, dan tekanan darah tinggi saat hamil (preeklamsia dan eklamsia). Banyak komplikasi tersebut bisa dikenali lebih awal dari pemeriksaan rutin seperti tekanan darah, gula darah, suhu tubuh, dan denyut jantung, sehingga pengelompokan tingkat risiko ibu hamil sejak dini penting agar ibu berisiko tinggi segera mendapat pemantauan dan rujukan.

Salah satu cara untuk mengklasifikasikan tingkat risiko tersebut adalah penambangan data (*data mining*). Dataset *Maternal Health Risk* dari UCI (Ahmed, 2020) sudah banyak dipakai dengan akurasi yang dilaporkan antara 61% sampai 97% (Ahmed & Kashem, 2020; Kurniawan, 2025; Uddin & Karim, 2025). Akan tetapi, saat penulis memeriksa dataset tersebut, ternyata 562 dari 1.014 baris (55,4%) merupakan salinan persis dari baris lain, bahkan ada satu kombinasi nilai yang muncul sampai 27 kali. Jika data dibagi secara acak, baris yang sama bisa masuk ke data latih dan data uji sekaligus, sehingga model seolah-olah sudah "melihat" jawabannya. Kondisi ini disebut kebocoran data (*data leakage*) yang membuat kinerja model terlihat lebih bagus daripada kemampuan sebenarnya (Kaufman et al., 2012) dan menjadi salah satu penyebab hasil penelitian *machine learning* sulit direproduksi (Kapoor & Narayanan, 2023).

Masalah ini penting diteliti karena dua alasan. Pertama, dalam skrining kesehatan kinerja yang terlalu tinggi bisa menyesatkan, karena model terlihat akurat tetapi saat dipakai pada pasien baru bisa gagal mengenali ibu berisiko tinggi (*false negative*). Pada studi pendahuluan penulis, macro-F1 Decision Tree turun dari 0,847 menjadi 0,613 setelah data duplikat ditangani (Subbab 2.2). Kedua, tenaga kesehatan membutuhkan model yang hasilnya bisa dijelaskan, bukan hanya akurat. Naive Bayes (NB), Decision Tree (DT), dan K-Nearest Neighbor (KNN) dipilih karena cara kerjanya berbeda, yaitu berbasis peluang, aturan, dan kemiripan data. Oleh karena itu, penulis membandingkan ketiga algoritma tersebut dengan cara evaluasi yang mencegah kebocoran data, lalu menerapkan model terbaik ke dalam aplikasi web untuk membantu skrining.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah penelitian ini adalah sebagai berikut.

1. Seberapa besar pengaruh data duplikat terhadap kinerja NB, DT, dan KNN pada dataset *Maternal Health Risk* jika tidak ditangani?
2. Bagaimana perbandingan NB, DT, dan KNN dilihat dari macro-F1, *recall* kelas Risiko Tinggi, kompleksitas, dan kemudahan interpretasi setelah kebocoran data dicegah?
3. Bagaimana pengaruh tuning *hyperparameter* dan label yang tidak konsisten terhadap kinerja masing-masing algoritma?
4. Bagaimana menerapkan model terbaik ke dalam aplikasi yang dapat menampilkan probabilitas dan alasan hasil prediksinya?

1.3 Tujuan Penelitian

1. Mengetahui seberapa besar kenaikan semu kinerja model akibat data duplikat dengan membandingkan evaluasi pada data mentah dan data tanpa duplikat.
2. Membandingkan NB, DT, dan KNN dengan cara pengujian yang sama, lalu menentukan model terbaik berdasarkan uji statistik.
3. Menganalisis pengaruh tuning *hyperparameter* dan label yang saling bertentangan terhadap kinerja model.
4. Membuat aplikasi web berbasis Streamlit menggunakan model terbaik sebagai prototipe alat bantu skrining.

1.4 Manfaat Penelitian

1. Bagi keilmuan, memberikan contoh cara evaluasi yang mencegah kebocoran data beserta kode program yang dapat diulang, serta menunjukkan dampak data duplikat pada dataset yang sering dipakai.
2. Bagi praktisi kesehatan, menghasilkan prototipe aplikasi edukatif untuk membantu bidan atau kader posyandu dalam skrining awal, lengkap dengan penjelasan hasil prediksinya.

1.5 Batasan Masalah

Penelitian ini dibatasi pada data sekunder dari Bangladesh (enam atribut, tiga kelas), algoritma NB, DT, dan KNN dengan *baseline* kelas mayoritas, serta aplikasi berupa prototipe edukatif yang belum divalidasi secara klinis.

BAB II STUDI LITERATUR

2.1 Penelitian Terdahulu

Penelitian tentang klasifikasi risiko ibu hamil dengan dataset yang sama dirangkum pada Tabel 1. Sebagian besar melaporkan akurasi di atas 80%, tetapi tidak ada yang menjelaskan bagaimana baris duplikat ditangani (setidaknya pada naskah atau abstrak yang dapat penulis akses).

Tabel 1. Ringkasan penelitian terdahulu pada dataset *Maternal Health Risk*

No	Peneliti	Metode	Validasi	Duplikat	Hasil utama
1	Ahmed & Kashem (2020)	Beberapa algoritma ML; *modified decision tree* (penelitian asal dataset)	Tidak dirinci di abstrak	Tidak disebutkan	Akurasi tertinggi 97% (*modified* DT)
2	Mustamin, Aziz, et al. (2023)	NB Gaussian, Multinomial, Bernoulli	5-*fold* CV	Tidak disebutkan (1.014 baris)	Akurasi 82,6% (Gaussian); 84,8% (Multinomial, Bernoulli)
3	Mustamin, Buang, et al. (2024)	5 teknik *ensemble* dibanding DT, KNN, NB	*Cross-validation*	Tidak disebutkan (1.014 baris)	*Bagged Trees* 85,6%; NB 82,6–84,8%; KNN 74,48%; DT 61,54%
4	Kurniawan (2025)	DT ID3, C4.5, NB, KNN + *grid search*	*Split* 70:30 (dipilih dari 60:40–90:10) dan 10-*fold* CV	Tidak dilakukan (1.014 baris)	DT 85,65% (setelah optimasi); KNN 82,62%, NB 61,31% (sebelum)
5	Uddin & Karim (2025)	9 algoritma (RF, XGBoost, SVM, KNN, NB, DT, dll.) + seleksi fitur Boruta	5-*fold* CV	Tidak disebutkan (1.014 baris)	RF terbaik: akurasi 89,1%, AUC 0,970
6	Saleem Altaie & Ibrahim (2026)	XGBoost, *blending*, *stacking*	*Hold-out* 80:20; SMOTEENN hanya pada data latih	Tidak disebutkan (n = 1.015)	Akurasi 80%, AUC 0,911, *recall* risiko tinggi 0,85

Hasil antarpenelitian juga cukup berbeda jauh. Akurasi DT berkisar dari 61,54% (Mustamin et al., 2024) sampai 85,65% (Kurniawan, 2025), dan NB dari 61,31% (Kurniawan, 2025) sampai 84,8% (Mustamin et al., 2023). Kurniawan (2025) memilih rasio pembagian data berdasarkan akurasi data uji, sehingga data uji ikut menentukan model. Sementara itu, penelitian yang menerapkan *oversampling* hanya pada data latih untuk menghindari kebocoran memperoleh akurasi 80% (Saleem Altaie & Ibrahim, 2026). Artinya, cara evaluasi sangat berpengaruh terhadap angka yang dilaporkan.

2.2 Celah Penelitian (Research Gap)

1. Data duplikat belum ditangani. Penelitian sebelumnya memakai seluruh 1.014 baris tanpa menjelaskan penghapusan duplikat, padahal 55,4% barisnya adalah salinan, dan belum ada yang mengukur seberapa besar kinerja NB, DT, dan KNN menjadi terlalu tinggi karenanya.
2. Cara pengujian tidak sama. Rasio pembagian data, cara tuning, dan validasinya berbeda-beda, dan tuning umumnya tidak dipisahkan dari pengujian (tanpa *nested cross-validation*), sehingga perbandingannya kurang adil.
3. Metrik terbatas. Kebanyakan hanya melaporkan akurasi, padahal setelah duplikat dihapus kelas menjadi tidak seimbang dan kesalahan pada kelas Risiko Tinggi paling berbahaya. Uji statistik juga jarang dilakukan.
4. Sisi penerapan kurang diperhatikan. Kompleksitas dan kemudahan interpretasi model jarang dibandingkan, dan model jarang dibuat menjadi aplikasi yang bisa menjelaskan prediksinya.

Celah pertama diperkuat oleh studi pendahuluan penulis (Tabel 2) yang menjalankan setiap algoritma dengan parameter bawaan pada data mentah (Skenario A) dan pada data tanpa duplikat dengan pembagian berbasis grup (Skenario B). Pada Skenario A, rata-rata 83,4% baris di setiap *fold* uji ternyata memiliki salinan persis di data latih, sedangkan pada Skenario B 0,0%.

Tabel 2. Hasil studi pendahuluan dengan parameter bawaan (rata-rata 10×10 *cross-validation*)

Algoritma	Akurasi A	Akurasi B	Macro-F1 A	Macro-F1 B	Selisih F1 (A − B)
Baseline (kelas mayoritas)	0,400	0,518	0,191	0,227	−0,036
Naive Bayes Gaussian	0,599	0,647	0,557	0,518	+0,039
Naive Bayes Kategorikal	0,622	0,667	0,621	0,554	+0,067
Decision Tree (CART)	0,843	0,675	0,847	0,613	+0,234
K-Nearest Neighbor (k = 5)	0,708	0,639	0,712	0,533	+0,179

2.3 Kontribusi Penelitian

Kontribusi yang diharapkan dari penelitian ini adalah (1) pemeriksaan kualitas data dan cara evaluasi yang mencegah kebocoran data (penghapusan duplikat, validasi berbasis grup, dan *nested cross-validation*) beserta kode program terbuka yang dapat diulang; (2) hasil pengukuran seberapa besar kinerja NB, DT, dan KNN menjadi terlalu tinggi akibat data duplikat; (3) perbandingan NB (dua varian), DT, dan KNN dengan metrik yang sesuai untuk kasus kesehatan (macro-F1 dan *recall* Risiko Tinggi), uji signifikansi, serta analisis kompleksitas dan interpretabilitas; dan (4) aplikasi web yang menampilkan probabilitas, peringatan jika input di luar rentang data latih, dan penjelasan prediksi untuk setiap algoritma.

BAB III RANCANGAN DATASET DAN ATRIBUT

3.1 Sumber dan Cara Memperoleh Data

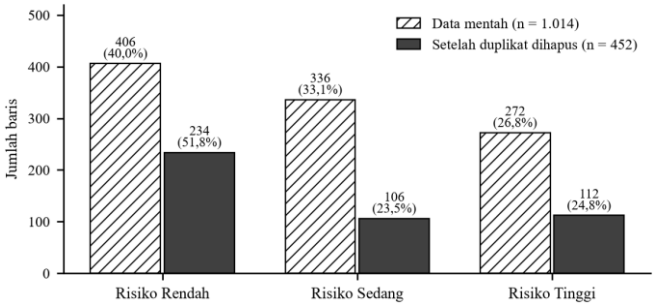
Data yang digunakan adalah data sekunder *Maternal Health Risk* (Ahmed, 2020) yang diunduh dari UCI Machine Learning Repository dalam bentuk file CSV (DOI 10.24432/C5DP5D, lisensi CC BY 4.0). Data ini adalah data asli (bukan sintetis) yang dikumpulkan dari rumah sakit, klinik komunitas, dan layanan kesehatan ibu di pedesaan Bangladesh melalui sistem pemantauan berbasis IoT (Ahmed & Kashem, 2020). Dataset berisi 1.014 baris dengan enam atribut prediktor numerik dan satu atribut target, tanpa nilai kosong. Setelah duplikat dihapus, tersisa 452 baris unik yang menjadi data utama pemodelan.

3.2 Atribut dan Variabel Target

Tabel 3. Atribut yang digunakan dalam penelitian

Atribut	Keterangan	Satuan	Rentang	Hubungan dengan risiko
Age	Usia ibu saat hamil	tahun	10–70	Usia terlalu muda atau terlalu tua meningkatkan risiko komplikasi
SystolicBP	Tekanan darah sistolik	mmHg	70–160	≥ 140 mmHg termasuk hipertensi kehamilan (Magee et al., 2022)
DiastolicBP	Tekanan darah diastolik	mmHg	49–100	≥ 90 mmHg termasuk hipertensi kehamilan (Magee et al., 2022)
BS	Kadar gula darah	mmol/L	6,0–19,0	Gula darah tinggi atau diabetes saat hamil
BodyTemp	Suhu tubuh	°F	98–103	Demam dapat menandakan infeksi (WHO, 2025)
HeartRate	Denyut jantung	bpm	7–90	Denyut cepat bisa menandakan perdarahan atau infeksi; nilai 7 bpm tidak wajar
RiskLevel	Target: tingkat risiko	kategori	3 kelas	*low*, *mid*, *high risk* (Rendah, Sedang, Tinggi)

Variabel target adalah **RiskLevel** yang terdiri dari tiga kelas, sehingga penelitian ini termasuk klasifikasi multikelas (*supervised learning*). Setelah duplikat dihapus, jumlah data tiap kelas menjadi 234 baris Risiko Rendah, 106 baris Risiko Sedang, dan 112 baris Risiko Tinggi (Gambar 1).



Gambar 1. Distribusi kelas sebelum dan sesudah duplikat dihapus

3.3 Alasan Pemilihan Atribut

Keenam atribut dipilih karena tiga alasan. Pertama, semuanya merupakan pemeriksaan kehamilan rutin yang murah, cepat, dan bisa dilakukan di puskesmas atau posyandu tanpa uji laboratorium yang mahal. Kedua, atribut tersebut berkaitan langsung dengan penyebab utama kematian ibu, yaitu hipertensi, infeksi, dan gangguan metabolik (WHO, 2025). Ketiga, korelasi Spearman pada data unik menunjukkan semua atribut berhubungan positif dengan tingkat risiko, yaitu gula darah 0,42, sistolik 0,31, suhu 0,27, usia 0,22, diastolik 0,22, dan denyut jantung 0,17. Sistolik dan diastolik memang berkorelasi cukup kuat (0,77),

tetapi keduanya tetap dipakai karena kriteria hipertensi memakai kedua nilai tersebut. Seleksi fitur tidak dilakukan karena atributnya hanya enam dan semuanya relevan.

3.4 Strategi Penanganan Kualitas Data

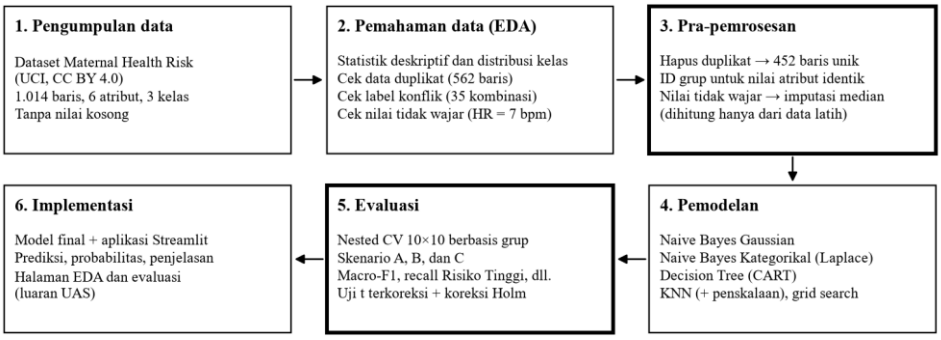
Tabel 4. Hasil pengecekan kualitas data dan cara penanganannya

Masalah	Temuan	Cara penanganan
Data kosong	Tidak ada nilai kosong	Imputasi median tetap disiapkan di *pipeline* untuk data baru; median dihitung dari data latih saja.
Data duplikat	562 baris duplikat persis (55,4%); 866 baris terlibat; ada yang berulang hingga 27×	Duplikat dihapus sehingga tersisa 452 baris. Data dibagi per grup nilai atribut agar baris identik tidak ada di data latih dan uji sekaligus. Data mentah hanya untuk pembanding (Skenario A).
Label tidak konsisten	35 kombinasi nilai atribut yang sama tetapi labelnya berbeda (71 baris)	Label tidak diubah agar data asli tidak dimanipulasi; barisnya dimasukkan ke satu grup. Pengaruhnya diuji di Skenario C (baris dihapus).
Nilai tidak wajar	HeartRate 7 bpm (2 baris mentah); usia 10–14 tahun (30) dan di atas 50 tahun (45)	Nilai di luar batas wajar (misalnya denyut di luar 40–200 bpm) dianggap kosong lalu diisi median data latih. Usia ekstrem tetap dipakai karena tercatat di sumber (dicatat sebagai keterbatasan).
Konsistensi logis	Semua baris memiliki sistolik > diastolik	Aturan ini juga dipakai untuk validasi input aplikasi.
Data kategorikal	Atribut prediktor numerik; target kategorikal	Target diubah ke angka secara otomatis; untuk NB Kategorikal atribut didiskretisasi (jumlah *bin* dan strateginya ikut di-tuning).
Skala dan kelas tidak seimbang	Rentang nilai antaratribut berbeda; Risiko Rendah 51,8%	Penskalaan untuk KNN (dipilih lewat tuning), stratifikasi saat membagi data, opsi *class weight* pada DT, dan metrik *macro*.

BAB IV METODE PENELITIAN

4.1 Tahapan Penelitian

Tahapan penelitian mengacu pada kerangka CRISP-DM (Wirth & Hipp, 2000) yang disesuaikan menjadi enam tahap (Gambar 2), yaitu pengumpulan data, pemahaman data, pra-pemrosesan, pemodelan, evaluasi, dan implementasi. Kotak bergaris tebal menunjukkan tahap yang membedakan penelitian ini dari penelitian sebelumnya.



Gambar 2. Tahapan penelitian

4.2 Konsep Algoritma dan Alasan Pemilihannya

Naive Bayes merupakan metode klasifikasi berdasarkan teorema Bayes dengan asumsi bahwa setiap atribut saling bebas jika kelasnya sudah diketahui (Han et al., 2012). Peluang data X masuk ke kelas C_k dihitung dengan persamaan berikut.

$$P(C_k \mid X) \propto P(C_k)\prod_{i=1}^{n} P(x_i \mid C_k) \quad (1)$$

Penelitian ini memakai dua varian NB, yaitu NB Gaussian yang menganggap atribut berdistribusi normal, dan NB Kategorikal yang mengubah atribut menjadi kategori lalu

memakai *Laplace smoothing* (α = 1, juga dicoba α = 0,5) agar tidak ada peluang yang bernilai nol, sesuai materi perkuliahan.

$$P(x_i \mid C_k) = \frac{1}{\sqrt{2\pi\sigma_{ik}^2}}\, exp\left(-\frac{(x_i-\mu_{ik})^2}{2\sigma_{ik}^2}\right),\ \ P(x_i = v \mid C_k) = \frac{n_{ikv}+\alpha}{n_k+\alpha V_i} \quad (2)$$

NB dipilih karena prosesnya cepat, parameternya sedikit (cocok untuk data kecil seperti 452 baris ini), dan menghasilkan probabilitas setiap kelas yang bisa diuraikan per atribut.

Decision Tree (CART) membagi data secara bertahap berdasarkan atribut dan nilai ambang yang paling banyak menurunkan ketidakmurnian simpul, yang diukur dengan indeks Gini atau entropi (Han et al., 2012).

$$Gini(D) = 1 - \sum_{k=1}^{K} p_k^2,\ \ Entropy(D) = -\sum_{k=1}^{K} p_k\, log_2\, p_k \quad (3)$$

DT dipilih karena menghasilkan aturan JIKA–MAKA yang mudah dibaca tenaga kesehatan, dapat menangkap batas nilai klinis (misalnya gula darah tinggi), dan tidak memerlukan penskalaan data. Untuk mencegah *overfitting*, kedalaman maksimum pohon dan jumlah minimum sampel pada daun ikut diatur.

K-Nearest Neighbor menentukan kelas suatu data berdasarkan suara terbanyak dari *k* tetangga terdekatnya. Jarak dihitung dengan jarak Minkowski, yaitu p = 1 untuk jarak Manhattan dan p = 2 untuk jarak Euclidean.

$$d(x, z) = (\sum_{i=1}^{n} |x_i - z_i|^p)^{1/p} \quad (4)$$

KNN dipilih karena dapat menangkap pola lokal tanpa asumsi distribusi data. KNN juga paling terpengaruh data duplikat karena salinan di data latih menjadi tetangga berjarak nol, sehingga cocok untuk melihat dampak kebocoran.

4.3 Persiapan Data untuk Pemodelan

Semua tahap pra-pemrosesan disusun dalam satu *pipeline* (validasi rentang dan imputasi, penskalaan untuk KNN atau diskretisasi untuk NB Kategorikal, lalu model) yang selalu dilatih hanya dengan data latih. Karena data unik hanya 452 baris, pembagian satu kali 70:30 atau 80:20 hasilnya kurang stabil, sehingga penulis memakai *repeated stratified group k-fold* 10×10, yaitu 10-*fold cross-validation* yang diulang 10 kali (100 pasangan data latih dan uji; Bouckaert & Frank, 2004). Tuning memakai *grid search* 5-*fold* di dalam data latih setiap *fold* (*nested cross-validation*) dengan skor macro-F1, sehingga data uji tidak pernah ikut memilih parameter (Varma & Simon, 2006). Implementasi memakai Python dan scikit-learn (Pedregosa et al., 2011) dengan *random seed* 42 (Tabel 5).

Tabel 5. *Hyperparameter* yang diuji pada *grid search*

Algoritma	Hyperparameter dan nilai yang diuji	Kombinasi
NB Gaussian	*var_smoothing*: 10^{-12} sampai 10^{-2} (11 nilai, skala log)	11
NB Kategorikal	jumlah *bin* {3, 4, 5, 6, 8, 10}; strategi {*quantile*, *uniform*, *k-means*}; α {0,5; 1}	36
Decision Tree	kriteria {Gini, entropi}; kedalaman maks {3, 4, 5, 6, 8, tanpa batas}; min. sampel daun {1, 3, 5, 10}; bobot kelas {tidak ada, seimbang}	96
KNN	k {1, 3, …, 29}; bobot {seragam, jarak}; p {1, 2}; penskalaan {tanpa, standar, min-max}	180

4.4 Alasan Pemilihan Metode Dibandingkan Alternatif Lain

Metode *ensemble* seperti Random Forest atau XGBoost bisa memberi akurasi lebih tinggi (Uddin & Karim, 2025), tetapi lebih sulit dijelaskan, tuningnya lebih berat, dan mudah *overfitting* pada 452 baris data, sehingga dijadikan pengembangan selanjutnya. SMOTE tidak dipakai karena data sintetis hasil interpolasi bisa memperkuat *noise* dari label yang

saling bertentangan. Validasi *hold-out* satu kali juga dihindari karena hasilnya sangat bervariasi pada data yang kecil.

BAB V RANCANGAN EKSPERIMEN DAN EVALUASI

5.1 Skenario Eksperimen

Eksperimen dilakukan dalam tiga skenario data (Tabel 6). Pada setiap skenario, empat model (NB Gaussian, NB Kategorikal, DT, dan KNN) diuji dengan parameter bawaan dan hasil tuning, ditambah *baseline*, sehingga totalnya 3 × 100 *fold* × 9 = 2.700 evaluasi. Untuk melihat kebocoran, penulis juga menghitung persentase baris uji yang memiliki salinan persis di data latih.

Tabel 6. Skenario eksperimen

Kode	Data	Validasi	Tujuan
A	Data mentah (1.014 baris)	Stratified 10×10 CV, setiap baris dianggap data yang berbeda	Meniru cara yang umum dipakai; pembanding untuk mengukur kebocoran
B (utama)	Data unik (452 baris)	Stratified group 10×10 CV + *nested* tuning	Mendapatkan perkiraan kinerja yang realistis (cara yang diusulkan)
C	Data unik tanpa label konflik (381 baris)	Sama dengan B	Melihat pengaruh label yang tidak konsisten

5.2 Metrik Evaluasi

Metrik utama adalah **macro-F1**, yaitu rata-rata F1 setiap kelas dengan bobot yang sama sehingga kelas yang jumlahnya sedikit tidak tertutupi kelas mayoritas (Risiko Rendah 51,8%). **Recall kelas Risiko Tinggi** dipakai sebagai metrik keselamatan karena ibu berisiko tinggi yang tidak terdeteksi (*false negative*) adalah kesalahan yang paling berbahaya.

$$F1_{macro} = \frac{1}{K}\sum_{k=1}^{K} 2 \cdot \frac{P_k R_k}{P_k + R_k}, \quad Recall_{tinggi} = \frac{TP}{TP+FN} \tag{5}$$

Metrik pendukungnya adalah akurasi (agar bisa dibandingkan dengan penelitian sebelumnya), *balanced accuracy*, presisi Risiko Tinggi, ROC-AUC *one-vs-rest*, dan *confusion matrix*. Kompleksitas diukur dari waktu latih, waktu prediksi per 1.000 data, dan ukuran model (jumlah simpul DT, data yang disimpan KNN, dan parameter NB), sedangkan interpretabilitas dilihat dari bentuk penjelasannya, yaitu aturan pohon (DT), kontribusi atribut (NB), atau tetangga terdekat (KNN).

5.3 Pembandingan dan Uji Statistik

Setiap algoritma dibandingkan dengan *baseline*, antara parameter bawaan dan hasil tuning, serta dengan algoritma lain. Skor dari *k-fold* berulang tidak saling bebas karena data latihnya tumpang tindih, sehingga uji t biasa terlalu mudah menyatakan hasil signifikan. Oleh karena itu, penulis memakai *corrected resampled t-test* (Nadeau & Bengio, 2003) dengan n = 100, n_1 jumlah data latih, dan n_2 jumlah data uji.

$$t = \frac{m_d}{\sqrt{\left(\frac{1}{n} + \frac{n_2}{n_1}\right) s_d^2}} \tag{6}$$

Pada persamaan tersebut, m_d dan s_d^2 adalah rata-rata dan variansi selisih skor kedua model. Nilai p dikoreksi dengan metode Holm (Holm, 1979) karena ada banyak perbandingan sekaligus (α = 0,05). Kenaikan semu (inflasi) kinerja dihitung dari metrik Skenario A dikurangi Skenario B. Model terbaik dipilih dengan aturan yang ditetapkan sejak awal, yaitu macro-F1 tertinggi pada Skenario B. Jika selisihnya dengan model lain tidak signifikan, dipilih model dengan *recall* Risiko Tinggi paling tinggi, lalu yang paling mudah dijelaskan.

5.4 Keterkaitan Hasil dengan Rumusan Masalah

Rumusan masalah (RM) 1 dijawab dengan selisih metrik antara Skenario A dan B serta persentase baris uji yang memiliki salinan di data latih. RM 2 dijawab dengan macro-F1, *recall* Risiko Tinggi, uji t terkoreksi, waktu, ukuran model, dan bentuk penjelasan keempat model pada Skenario B. RM 3 dijawab dari perubahan metrik antara parameter bawaan dan hasil tuning, serta antara Skenario B dan C. RM 4 dijawab dengan hasil pengujian *black-box* aplikasi dan waktu responsnya.

5.5 Luaran dan Kriteria Keberhasilan

Luaran yang diharapkan adalah perbandingan kinerja yang realistis, rekomendasi algoritma terbaik, dan aplikasi web. Target ditentukan dari studi pendahuluan (Tabel 2), bukan dari angka penelitian sebelumnya yang mungkin bias. Penelitian dianggap berhasil apabila:

1. kenaikan semu kinerja akibat duplikasi terukur, yaitu selisih macro-F1 Skenario A dan B minimal 0,05 pada sedikitnya satu algoritma;
2. model terbaik pada Skenario B mendapatkan macro-F1 minimal 0,60 dan *recall* Risiko Tinggi minimal 0,70, serta signifikan lebih baik daripada *baseline* (p Holm $< 0,05$);
3. aplikasi lolos semua kasus uji fungsional (input valid dan tidak valid, konversi satuan, dan prediksi dari file CSV) dengan waktu respons prediksi kurang dari 1 detik.

BAB VI RENCANA PELAKSANAAN PENELITIAN

6.1 Target Capaian

Target capaian penelitian ini adalah (1) laporan penelitian lengkap untuk UAS, (2) repositori GitHub berisi data, kode program, dan model sehingga hasilnya dapat diulang, (3) aplikasi web Streamlit yang dapat diakses secara *online*, dan (4) bahan presentasi.

6.2 Jadwal Kegiatan

Tabel 7. Jadwal kegiatan penelitian (minggu ke-1 sampai ke-8 setelah UTS)

Kegiatan	1	2	3	4	5	6	7	8
Studi literatur dan finalisasi proposal	■							
Pengumpulan data, EDA, dan cek kualitas data	■	■						
Pra-pemrosesan dan penyusunan *pipeline*		■	■					
Pemodelan dan tuning NB, DT, KNN			■	■				
Eksperimen Skenario A/B/C dan uji statistik				■	■			
Pembuatan aplikasi Streamlit					■	■		
Pengujian aplikasi dan *deployment*							■	
Penyusunan laporan akhir dan presentasi UAS							■	■

6.3 Pembagian Tugas

Penelitian ini dikerjakan secara mandiri, sehingga seluruh tahapan mulai dari studi literatur, pengolahan data, eksperimen, pembuatan aplikasi, sampai penulisan laporan menjadi tanggung jawab penulis dengan bimbingan dosen pengampu.

6.4 Rencana Implementasi dan Pemanfaatan

Model terbaik diimplementasikan menjadi aplikasi web Streamlit yang di-*deploy* dari GitHub ke Streamlit Community Cloud. Aplikasi terdiri dari empat halaman, yaitu (1) **Prediksi Risiko** untuk memasukkan enam hasil pemeriksaan (bisa dalam mg/dL dan °C) lalu menampilkan kelas risiko, probabilitas, peringatan jika input di luar rentang data latih, penjelasan prediksi (jalur aturan DT, kontribusi atribut NB, atau tetangga terdekat KNN), serta prediksi dari file CSV; (2) **Eksplorasi Data**; (3) **Evaluasi Model** untuk Skenario A,

B, dan C; dan (4) **Tentang**. Aplikasi ini ditujukan sebagai sarana edukasi dan alat bantu skrining awal bagi bidan atau kader posyandu, bukan untuk diagnosis. Sebelum dipakai di lapangan, model perlu divalidasi dengan data ibu hamil Indonesia, misalnya data puskesmas.

DAFTAR PUSTAKA

Ahmed, M. (2020). *Maternal health risk* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5DP5D

Ahmed, M., & Kashem, M. A. (2020). IoT based risk level prediction model for maternal health care in the context of Bangladesh. *2020 2nd International Conference on Sustainable Technologies for Industry 4.0 (STI)*, 1–6. https://doi.org/10.1109/STI50764.2020.9350320

Badan Pusat Statistik. (2026). *Penduduk dan indikator kependudukan hasil Survei Penduduk Antar Sensus 2025*. Badan Pusat Statistik.

Bouckaert, R. R., & Frank, E. (2004). Evaluating the replicability of significance tests for comparing learning algorithms. Dalam *Advances in Knowledge Discovery and Data Mining (PAKDD 2004)* (hlm. 3–12). Springer. https://doi.org/10.1007/978-3-540-24775-3_3

Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (Edisi ke-3). Morgan Kaufmann.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics, 6*(2), 65–70.

Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns, 4*(9), 100804. https://doi.org/10.1016/j.patter.2023.100804

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data, 6*(4), 1–21. https://doi.org/10.1145/2382577.2382579

Kurniawan, A. (2025). Perbandingan optimasi algoritma klasifikasi decision tree, naive bayes dan KNN menggunakan optimize parameter grid pada tingkat resiko ibu hamil. *Faktor Exacta, 18*(2), 111–119. https://doi.org/10.30998/faktorexacta.v18i2.28051

Magee, L. A., Brown, M. A., Hall, D. R., Gupte, S., Hennessy, A., Karumanchi, S. A., Kenny, L. C., McCarthy, F., Myers, J., Poon, L. C., Rana, S., Saito, S., Staff, A. C., Tsigas, E., & von Dadelszen, P. (2022). The 2021 International Society for the Study of Hypertension in Pregnancy classification, diagnosis & management recommendations for international practice. *Pregnancy Hypertension, 27*, 148–169. https://doi.org/10.1016/j.preghy.2021.09.008

Mustamin, N. F., Aziz, F., Firmansyah, F., & Ishak, P. (2023). Classification of maternal health risk using three models naive bayes method. *IJCCS (Indonesian Journal of Computing and Cybernetics Systems), 17*(4), 395–404. https://doi.org/10.22146/ijccs.84242

Mustamin, N. F., Buang, A., Aziz, F., & Nur, N. H. (2024). Ensemble techniques based risk classification for maternal health during pregnancy. *ILKOM Jurnal Ilmiah, 16*(2), 190–197. https://doi.org/10.33096/ilkom.v16i2.2005.190-197

Nadeau, C., & Bengio, Y. (2003). Inference for the generalization error. *Machine Learning, 52*(3), 239–281. https://doi.org/10.1023/A:1024068626366

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Saleem Altaie, H. K., & Ibrahim, A. A. (2026). Development of an advanced maternal health risk detection system using enhanced XGBOOST and blending models. *Digital Health, 12*, 20552076261450786. https://doi.org/10.1177/20552076261450786

Uddin, M. M., & Karim, M. R. (2025). Comparative evaluation of machine learning models for maternal health risk prediction using IoT-based data. *International Journal of Statistical Sciences, 25*(2), 59–80. https://doi.org/10.3329/ijss.v25i2.85735

Varma, S., & Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics, 7*, 91. https://doi.org/10.1186/1471-2105-7-91

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 29–39.

World Health Organization. (2025, 7 April). *Maternal mortality* [Lembar fakta]. https://www.who.int/news-room/fact-sheets/detail/maternal-mortality